

Prueba Técnica

Data Scientist Senior - Banca Analítica

Diapositiva

1. Presentación

Solución de ciencia de datos productiva para riesgo financiero y fraude con agente IA

- Proyecto: Finance IA Test
- Repositorio: <https://github.com/JulianTorrest/Finance-IA-Test>
- Fecha: Octubre 2026

2. Objetivos del proyecto


1. Construir un modelo de riesgo financiero que evolucione con el cliente.
2. Detectar comportamientos transaccionales atípicos con enfoque de fraude.
3. Habilitar un agente inteligente IA que traduzca análisis en acciones.
4. Aplicar buenas prácticas de ciclo de vida de modelos (MLOps).
5. Exponer resultados vía Streamlit y FastAPI para usuarios y sistemas.

3. Cronograma

Fase	Duración	Entregable
-----	-----	-----
Análisis y diseño	1-2 días	Arquitectura y supuestos
Datos y features	1 día	Datos dummy y pipeline ETL
Modelado	2-3 días	Modelos entrenados y catálogo
Integración LLM y UI	2 días	Streamlit y agente IA
MLOps y API	2 días	Tests, drift, retraining, FastAPI
Sustentación	1 día	Presentación y documentación

Total estimado: 9-11 días hábiles.

4. Arquitectura



Capas principales:

- Ingesta y preparación: `src/generate_data.py`
- Entrenamiento: `src/model_catalog.py`, `src/train_models.py`
- Serving: `src/predict.py` y `api/main.py`
- Experiencia: `app/streamlit_app.py`
- MLOps: `src/retrain.py`, `src/drift.py`, `tests/`

5. Modelos desarrollados

Riesgo financiero

- Random Forest
- Gradient Boosting
- Logistic Regression

Fraude transaccional

- Isolation Forest (no supervisado)
- Random Forest (supervisado)

El usuario puede seleccionar el modelo en la UI y en la API.

6. Resultados

Métricas de modelos

Modelo	Métrica principal	Valor
-----	-----	-----
Riesgo - Random Forest	ROC-AUC	0.974
Riesgo - Logistic Regression	ROC-AUC	0.976
Fraude - Isolation Forest	F1	0.249
Fraude - Random Forest	F1	0.092

Cobertura

- 5.000 clientes analizados.
- 100.000 transacciones evaluadas.
- 100% de clientes scorificados.

7. Impacto de negocio

- Reducción de pérdidas: detección temprana de clientes de alto riesgo.
- Eficiencia operativa: fraude detectado automáticamente para revisión.
- Toma de decisiones: el agente IA entrega recomendaciones accionables en lenguaje natural.
- Escalabilidad: FastAPI permite integración con canales digitales del banco.
- Gobernanza: registro, versionamiento, drift y retraining incluidos.

8. Agente IA

- Integración con Mistral y Groq con fallback.
- Responde en markdown con secciones: resumen, factores, acción, urgencia, riesgo, justificación.
- Compara predicciones de múltiples modelos de ML.
- Contexto enriquecido: cliente, cuentas, transacciones recientes, scores.

9. MLOps implementado

Capacidad	Estado
-----	-----
Registro de modelos	(OK)
Versionamiento	(OK)
Tests automatizados (pytest)	(OK)
Drift monitoring (PSI/KS)	(OK)
Retraining automático	(OK)
API REST (FastAPI)	(OK)
Documentación	(OK)

10. Supuestos clave

- Datos sintéticos para la demo; en producción vendrían del data warehouse.
- Target de riesgo construido con reglas de negocio.
- Tasa de fraude simulada ~2%.
- API keys de Mistral/Groq en tier gratuito.

11. Roadmap

Corto plazo

- SHAP para explicabilidad.
- A/B testing y shadow mode.
- Dockerización.

Mediano plazo

- Feature store.
- MLflow / experiment tracking.
- CI/CD con GitHub Actions.

Largo plazo

- Kubernetes / cloud deployment.
- Multitenencia.
- XGBoost y autoencoders.

12. Cierre

La solución entrega:

- (OK) Datos, modelos y UI funcionales.
- (OK) Catálogo de modelos seleccionables.
- (OK) Agente IA con fallback y comparación de modelos.
- (OK) MLOps: registro, drift, retraining y tests.
- (OK) API REST para integración con otros sistemas.
- (OK) Presentación ejecutiva lista para sustentación.

¡Gracias!